2022 DACON
HOUSE PRICE PREDICTION CONTEST

김 재 원

CONTENTS

01 프로젝트 개요

02 Pycaret과 사용 라이브러리 버전

03 데이터 전처리와 시각화

04 모델링

05 참고자료

01

프로젝트 개요

1.프로젝트 개요

- 데이터 셋에 이상치와 결측치가 있는지 여부를 확인
- 데이터 전처리 및 시각화 구현
- 여러 모델을 성능 평가 지표를 기준으로 비교해 적합한 모델 적용

1.프로젝트 개요

<대회 소개>

Dacon(데이콘) – 집값 예측 경진대회

- **대회 기간 : 2022.01.24 ~ 2022.02.04 (10일간 진행)**
- **대회 목적 : ‘housing data(기본 데이터 셋)’을 이용한 집값 예측**

1.프로젝트 개요

- 프로젝트 기간: 2022-01-24 ~ 2022-01-28
- 팀: 단독 프로젝트(혼자 진행)
- 사용 언어 : Python
- 사용 데이터 : [Dacon-집값 예측 경진대회] (Train file, Test file, Submission File)
- 라이브러리 : matplotlib, numpy, seabron, pandas, plotly, pycaret
- 내용 : ‘housing’(기본 데이터 셋)을 이용해 ‘pycaret’과 ‘blend model’ 을 써서 가장 적합한 모델을 적용하고 최종 예측 값을 출력하는 프로젝트

02

Pycaret
&
사용 라이브러리 버전

2.Pycaret과 사용 라이브러리 버전

- **Pycaret**
  - ‘Python’의 오픈 소스 라이브러리
  - 머신러닝의 워크 플로우를 자동화 처리 (Auto ML)
  - 코딩, 전처리, 모델 선택, 파라미터 튜닝 작업 등을 자동으로 진행

2.Pycaret과 사용 라이브러리 버전

라이브러리	버 전
Pycaret	2.3.6
Pandas	1.3.5
Seaborn	0.11.2
Numpy	1.19.5
Matplotlib	3.2.2
Plotly	5.5.0

2.Pycaret과 사용 라이브러리 버전

< Pycaret (파이 캐롯) 워크 플로우>

2.Pycaret과 사용 라이브러리 버전

< Fast API>

- ‘FastAPI’ 는 표준 Python을 기반으로 Python 3.6 이상으로

  ‘API’를 생성하기 위한 최신의 빠른 웹 프레임워크

  FastAPI

<특징>

- 빠른 속도 : ‘Node.JS’ 및 ‘Go’와 같은 매우 높은 성능, 사용 가능한 가장 빠른 Python 프레임워크 중 하나
- 빠른 코드 입력 : 기능 개발 속도를 약 200%에서 300%까지 높여준다.
- 사용이 쉽다 : 사용하고 배우기 쉽도록 설계되었다. 문서를 읽는 시간이 줄어든다.

03

데이터 전처리
&
시각화

3.데이터 전처리와 시각화

<데이터 셋 설명>

데이터셋 구성		정수형 데이터	객체형 데이터	전체 크기
총 데이터	train	12	3	0.35MB
	test	12	3	0.34MB
			전체 파일 크기	0.69MB
데이터 출처: https://colab.research.google.com/drive/1lXApWFCzsIaTrNG3Ppm7R4Kqsxu08rEQ				

3.데이터 전처리와 시각화

<데이터 구성>

train & test
id
OverallQual : 집의 재료와 마감 품질
YearBuilt : 완공 연도
YearRemodAdd : 리모델링 연도
ExterQual : 외관 재료 품질
BsmtQual : 지하실 높이
TotalBsmtSF : 지하실 면적
1stFlrSF : 1층 면적
GrLivArea : 지상층 생활 면적
FullBath : 지상층 화장실 개수
KitchenQual : 부엌 품질
GarageYrBlt : 차고 완공 연도
GarageCars: 차고 자리 개수
GarageArea: 차고 면적
target : 집값(달러 단위) - train에만 존재

3.데이터 전처리와 시각화

- ‘train’ 데이터에만 ‘target(집값)’이 있는 것 확인

train

	id	Overall Qual	Gr Liv Area	Exter Qual	Garage Cars	Garage Area	Kitchen Qual	Total Bsmt SF	1st Flr SF	Bsmt Qual	Full Bath	Year Built	Year Remod/Add	Garage Yr Blt	target
0	1	10	2392	Ex	3	968	Ex	2392	2392	Ex	2	2003	2003	2003	386250
1	2	7	1352	Gd	2	466	Gd	1352	1352	Ex	2	2006	2007	2006	194000
2	3	5	900	TA	1	288	TA	864	900	TA	1	1967	1967	1967	123000
3	4	5	1174	TA	2	576	Gd	680	680	TA	1	1900	2006	2000	135000
4	5	7	1958	Gd	3	936	Gd	1026	1026	Gd	2	2005	2005	2005	250000

test

	id	Overall Qual	Gr Liv Area	Exter Qual	Garage Cars	Garage Area	Kitchen Qual	Total Bsmt SF	1st Flr SF	Bsmt Qual	Full Bath	Year Built	Year Remod/Add	Garage Yr Blt
0	1	9	1800	Gd	2	702	Ex	1800	1800	Ex	2	2007	2007	2007
1	2	6	1082	TA	1	240	TA	1082	1082	TA	1	1948	1950	1948
2	3	6	1573	Gd	2	440	Gd	756	769	Gd	2	2000	2000	2000
3	4	6	2443	Gd	3	744	Gd	1158	1158	Gd	2	2004	2004	2004
4	5	5	1040	TA	2	686	TA	1040	1040	TA	1	1968	1968	1991

3.데이터 전처리와 시각화

- ‘2000년’이후에 ‘리모델링’을 가장 많이 했다는 것 확인 가능

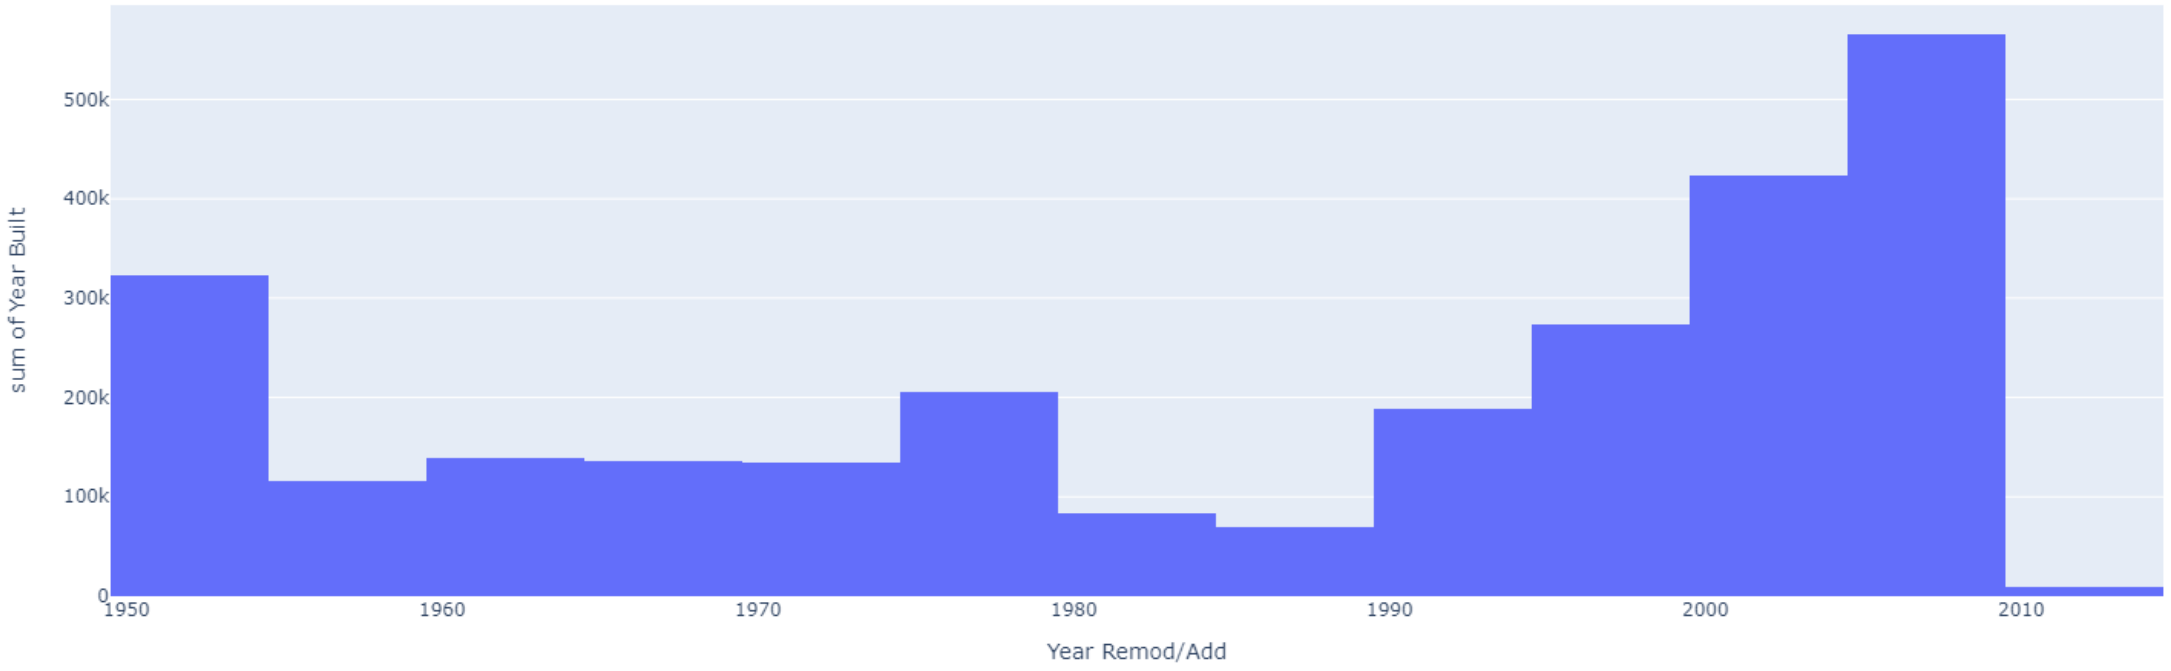

3.데이터 전처리와 시각화

- ‘2000년’-’2009년’에 가장 ‘집값’이 비싼 것 확인 가능

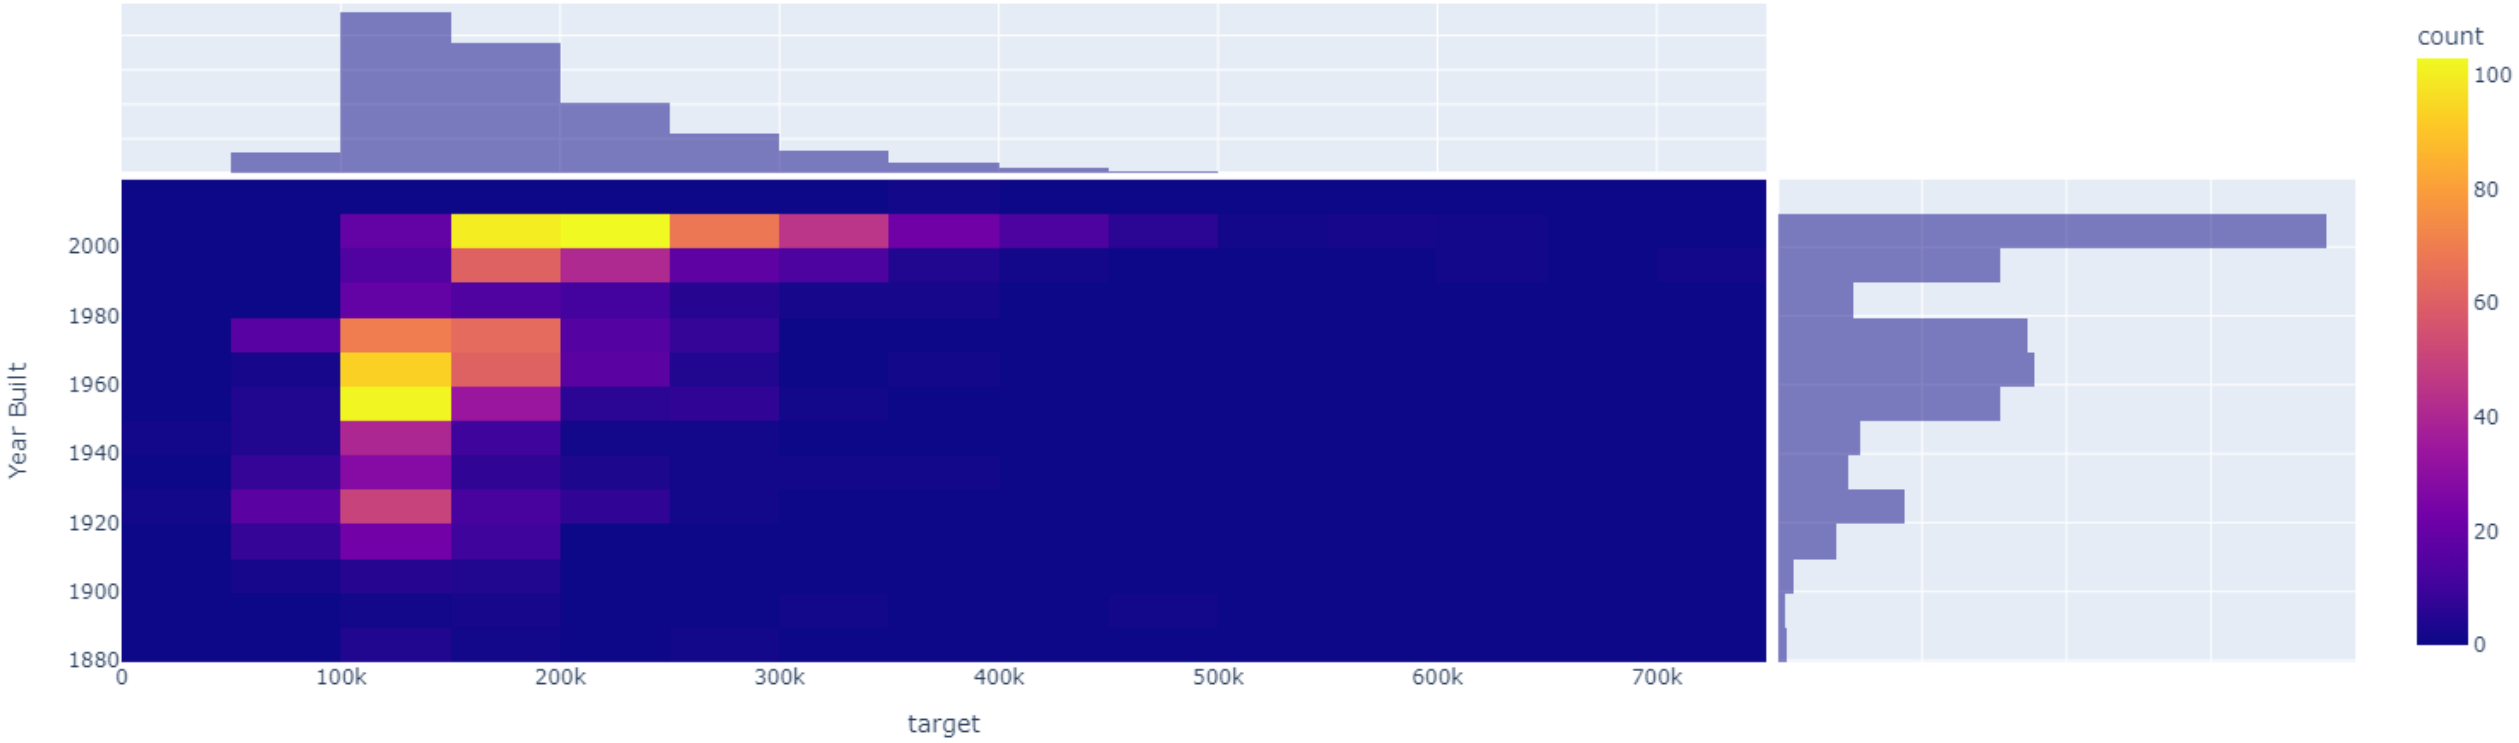

04

모델링

4.모델링

<‘blend model( )'의 워크 플로우 구조>

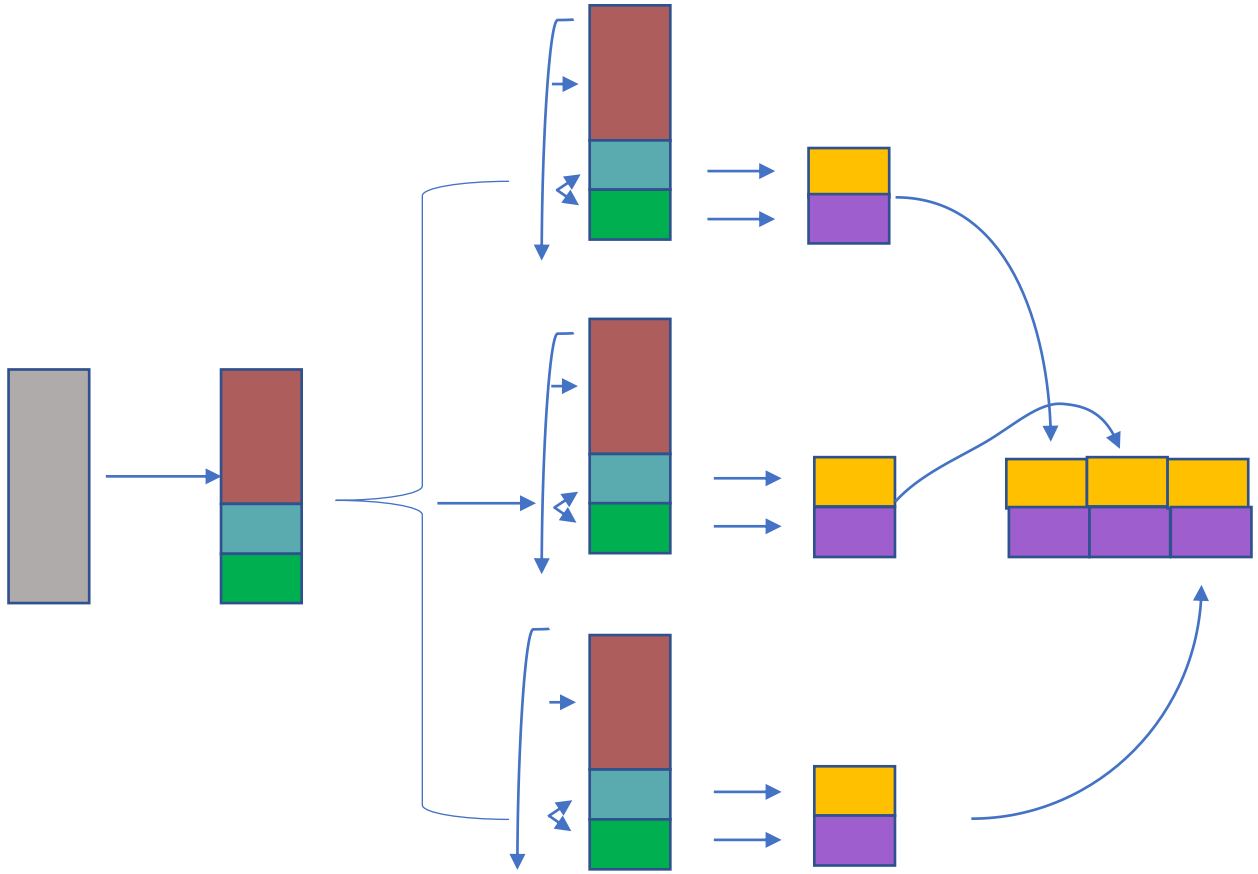

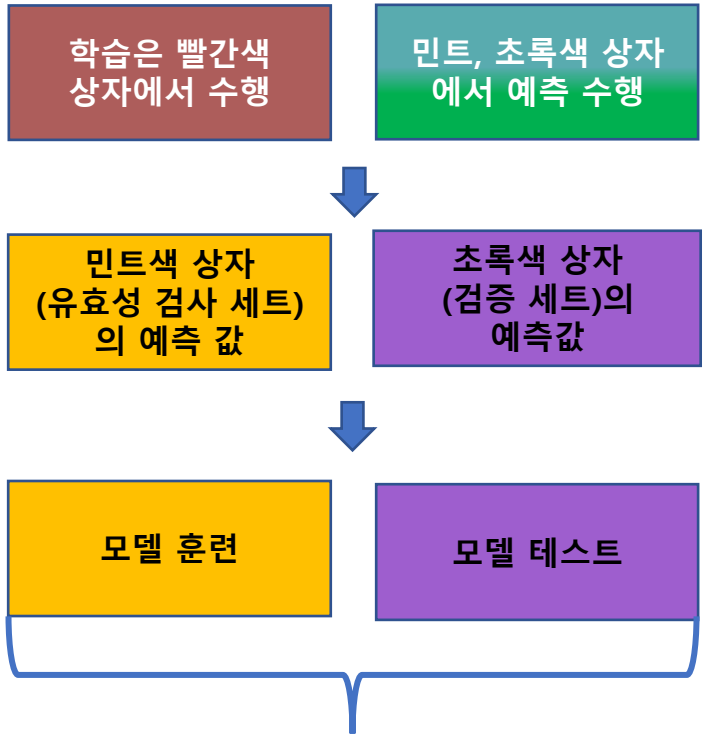

최종적으로 노란색 상자 => 모델 훈련 수행

보라색 상자 => 모델 테스트 수행

4.모델링

- 성능 평가 지표

평가지표명	NMAE	MAE
설명	데이콘 대회에서 시계열 키워드 대회에서 많이 보이는 평가지표, 값이 작을수록 잘 예측	예측 값과 실제 값 차이의 절대값을 구해 이를 평균을 낸 지표, 값이 작을 수록 잘 예측
특징	정규화된 MAE이기 때문에 편향되지 않아 과소평가와 과대평가 모두에 대해 유사한 해석 제공	예측변수와 같은 단위를 사용
장점	크기가 다른 데이터셋의 MAE 비교에 용이	지표 자체가 직관적이다.
단점	절대값을 취하기 때문에 실제보다 낮은 값인지 큰 값인지 알 수 없다.	

4.모델링

- 상위 3개의 모델을 비교해 가장 적합한 모델 선택

	Model	Accuracy	AUC	Recall	Prec	F1	Kappa	NMAE	TT(Sec)
rf	Random Forest Classifer	0.007	0.0	0.004	0.0052	0.005	0.004	0.14	5.1
lightgbm	Light Gredient Boosting Machine	0.008	0.0	0.004	0.0079	0.007	0.005	0.15	39.0
dt	Decision Tree Classifer	0.005	0.0	0.002	0.0057	0.004	0.002	0.16	0.07

4.모델링

- 상위 3개의 모델을 혼합해 1차 결과 값 출력

	Accuracy	AUC	Recall	Prec	F1	Kappa	NMAE
0	0.0	0.0	0.0	0.0	0.0	-0.1	0.15
1	0.0	0.0	0.0	0.0	0.0	-0.3	0.13
2	0.2	0.0	0.1	0.1	0.1	0.1	0.11
3	0.0	0.0	0.0	0.0	0.0	-0.3	0.15
4	0.1	0.0	0.6	1.0	0.1	-0.8	0.14
5	0.0	0.0	0.0	0.0	0.0	-0.3	0.11
6	0.0	0.0	0.0	0.0	0.0	-0.3	0.11
7	0.0	0.0	0.0	0.0	0.0	-0.3	0.14
8	0.1	0.0	0.6	0.5	0.7	0.7	0.16
9	0.1	0.0	0.6	0.1	0.1	0.7	0.14
Mean	0.5	0.0	0.3	0.3	0.4	0.2	0.13
SD	0.7	0.0	0.4	0.4	0.5	0.7	0.1

4.모델링

- 최종 예측 값 출력

	Model	Accuracy	AUC	Recall	Prec	F1	Kappa	MCC	NMAE
0	Voting Classifier	0.9	0	0.9	0.9	0.9	0.9	0.9	0.1

4.모델링

<예측 방정식>

예측 방정식
대회 규칙의 평가 산식 함수를 그대로 사용합니다. def NMAE(true, pred): mae = np.mean(np.abs(true-pred)) score = mae / np.mean(np.abs(true)) return score

# 실제 정답 값을 준비합니다. 	
real_answer = Y.copy()
 	
# 정답과 예측 값을 함수에 넣어 결과를 확인합니다. 	
error = NMAE(real_answer, predict_Y)
 	
print(f"이 방정식의 평균 에러는 {error:.2f} 입니다.")

# 위에서 구한 예측값을 그대로 넣어줍니다. 	
submission[y_feature] = predict_test
 	
# 데이터가 잘 들어갔는지 확인합니다. 	
submission

4.모델링

<‘Pandas Profiling’>

라이브러리명	Pandas Profiling
설명	‘EDA(탐색적 자료 분석)’을 자동화하여 ‘report(보고서)’ 형태로 생성
장점	자동화로 작업시간이 단축된다.
단점	속도가 비교적 느리다.

- 이번 데이콘 집값 예측 경진대회 데이터 : <u>‘Pandas Profiling’</u>

05

참고자료
&
리더보드

5.참고자료 & 리더보드

- https://dacon.io/competitions/official/235869/codeshare/4267?page=1&dtype=recent
- https://towardsdatascience.com/ensemble-learning-stacking-blending-voting-b37737c4f483
- https://dacon.io/competitions/official/235869/codeshare/4253?page=1&dtype=recent

5.참고자료 & 리더보드

PUBLIC PRIVATE RANKING CHART

순위기준

WINNER 1% 4% 10%

전체 랭킹 >

#	팀		팀 멤버	점수	제출수	등록일
73	kimjaewon	ki		0.09598	6	3일 전
1	Ohmygod			0.09162	30	2시간 전
2	ksh			0.09166	26	4시간 전
3	초심	AD		0.09203	18	하루 전
4	롤케잌	롤케		0.09219	35	17시간 전
5	빙수			0.09262	13	5일 전
6	음음찌			0.09275	24	6시간 전

THANK YOU