Kaggle 2022 T.P.S

김 재 원

CONTENTS

01 프로젝트 개요

02 Pycaret과 사용 라이브러리 버전

03 데이터 전처리와 시각화

04 모델링

05 참고 자료

CONTENTS

01 프로젝트 개요

- 데이터 셋에 이상치와 결측치가 있는지 여부를 확인
- 데이터 전처리 및 시각화 구현
- 모델 성능 평가 지표로 정확도를 측정함

01 데이터 셋 설명

데이터셋 구성		정수형 데이터	객체형 데이터	전체 크기
총 데이터	train	26298	1314	7.06MB
	test	6023 (날짜 시간형 데이터)	547	1.71MB
			전체 파일 크기	8.77MB
데이터 출처: https://www.kaggle.com/kjw3226/t-p-s-preprocessing-visualization-modeling				

train

row_id	date	country	store	product	num_sold
0	2015-01-01	Finland	KaggleMart	Kaggle Mug	329
1	2015-01-01	Finland	KaggleMart	Kaggle Hat	520
2	2015-01-01	Finland	KaggleMart	Kaggle Sticker	146
3	2015-01-01	Finland	KaggleRama	Kaggle Mug	572
4	2015-01-01	Finland	KaggleRama	Kaggle Hat	911

test

row_id	date	country	store	product
26298	2019-01-01	Finland	KaggleMart	Kaggle Mug
26299	2019-01-01	Finland	KaggleMart	Kaggle Hat
26300	2019-01-01	Finland	KaggleMart	Kaggle Sticker
26301	2019-01-01	Finland	KaggleRama	Kaggle Mug
26302	2019-01-01	Finland	KaggleRama	Kaggle Hat

01 Kaggle competition

- Tabular Playground Series – Jan 2022

- 대회 기간 : 2022-01-01 ~ 2022-01-31

- 대회 목적 : a fun, and approachable 를 위해 anyone에게 tabular dataset 제공

02 Pycaret과 사용 라이브러리 버전

< Pycaret (파이 캐롯) >

- ‘Python’의 오픈 소스 라이브러리
- 머신러닝의 워크 플로우를 자동화 처리 (Auto ML)
- 코딩, 전처리, 모델 선택, 파라미터 튜닝 작업 등을 자동으로 진행

02 Pycaret과 사용 라이브러리 버전

- 프로젝트 주요 라이브러리 버전

라이브러리	버 전
Pycaret	2.3.5
Pandas	1.3.4
Seaborn	0.11.2
Numpy	1.19.5
Matplotlib	3.5.0
Plotly	5.4.0

02 Pycaret과 사용 라이브러리 버전

< Pycaret (파이 캐롯) 워크 플로우>

03 데이터 전처리와 시각화

```
train.isnull().sum()
```

```
date        0
country     0
store       0
product     0
num_sold    0
dtype: int64
```

```
test.isnull().sum()
```

```
date        0
country     0
store       0
product     0
dtype: int64
```

```
train.isna().sum()
```

```
4]: date        0
    country     0
    store       0
    product     0
    num_sold    0
    dtype: int64
```

```
test.isna().sum()
```

```
date        0
country     0
store       0
product     0
dtype: int64
```

- **‘train‘, ‘test’ 데이터에 결측치, 이상치 모두 없다.**

03 데이터 전처리와 시각화

```python
# Code Source : https://www.kaggle.com/subinium/tps-jan-happy-new-year
print('train date duration : ', train['date'].min(), train['date'].max())
print('test date duration : ', test['date'].min(), test['date'].max())
```

```
train date duration :  2015-01-01 2018-12-31
test date duration :  2019-01-01 2019-12-31
```

- 'train' 데이터는 '2015년' ~ '2018년' 까지의 3년간의 데이터
- 'test' 데이터는 '2019년'의 1년간의 데이터

```python
# Code Source : https://www.kaggle.com/subinium/tps-jan-happy-new-year
train['date'] = pd.to_datetime(train['date'])
test['date'] = pd.to_datetime(test['date'])
```

- 날짜 'column'이 '문자형' 이기 때문에 'pandas'에서 처리하기 쉽게 'datetime'형으로 변환

03 데이터 전처리와 시각화

```
# Code Source : https://www.kaggle.com/subinium/tps-jan-happy-new-year
train_date = train.set_index('date').pivot(columns=['country', 'store', 'product'], values='num_sold')
train_date.head()
```

- **'train' 데이터를 '날짜 별'로 pivot 테이블로 만들어준다.**

<실행 화면>

country	Finland						Norway						Sweden					
store	KaggleMart			KaggleRama			KaggleMart			KaggleRama			KaggleMart			KaggleRama		
product	Kaggle Mug	Kaggle Hat	Kaggle Sticker	Kaggle Mug	Kaggle Hat	Kaggle Sticker	Kaggle Mug	Kaggle Hat	Kaggle Sticker	Kaggle Mug	Kaggle Hat	Kaggle Sticker	Kaggle Mug	Kaggle Hat	Kaggle Sticker	Kaggle Mug	Kaggle Hat	Kaggle Sticker
date																		
2015-01-01	329	520	146	572	911	283	526	906	250	1005	1461	395	440	624	175	706	1195	324
2015-01-02	318	493	127	544	794	249	538	845	237	949	1446	415	384	572	155	653	986	293
2015-01-03	360	535	141	579	843	265	614	930	254	1029	1631	451	420	630	173	734	1167	319
2015-01-04	332	544	125	582	873	245	589	889	255	957	1540	455	406	697	169	657	1112	300
2015-01-05	243	378	102	423	668	187	435	671	184	739	1126	310	298	442	127	512	796	227

03 데이터 전처리와 시각화

```
# Code Source : https://www.kaggle.com/subinium/tps-jan-happy-new-year
train_month = train.set_index('date').groupby([pd.Grouper(freq='M'), 'country', 'store', 'product'])['num_sold'].mean().unstack([1, 2, 3])
train_month_country = train.set_index('date').groupby([pd.Grouper(freq='M'), 'country'])['num_sold'].mean().unstack()
train_month.head()
```

- **'train' 데이터를 '월별'로 그룹지어 묶어 주었다.**

< 실행 화면>

country	Finland						Norway						Sweden					
store	KaggleMart			KaggleRama			KaggleMart			KaggleRama			KaggleMart			KaggleRama		
product	Kaggle Hat	Kaggle Mug	Kaggle Sticker	Kaggle Hat	Kaggle Mug	Kaggle Sticker	Kaggle Hat	Kaggle Mug	Kaggle Sticker	Kaggle Hat	Kaggle Mug	Kaggle Sticker	Kaggle Hat	Kaggle Mug	Kaggle Sticker	Kaggle Hat	Kaggle Mug	Kaggle Sticker
date																		
2015-01-31	367.612903	221.193548	97.096774	623.967742	388.903226	172.129032	613.451613	382.645161	167.516129	1074.225806	650.419355	290.419355	436.290323	269.516129	119.032258	769.387097	470.096774	204.064516
2015-02-28	362.928571	193.535714	88.928571	632.857143	341.785714	154.178571	623.321429	338.857143	154.928571	1096.964286	587.535714	269.750000	441.107143	239.142857	108.821429	749.714286	408.642857	191.607143
2015-03-31	383.774194	185.967742	90.290323	663.516129	324.387097	156.419355	656.096774	322.548387	157.096774	1165.290323	555.419355	272.193548	455.580645	224.096774	107.225806	800.612903	397.129032	189.322581
2015-04-30	407.800000	184.633333	95.666667	704.733333	317.800000	167.466667	736.266667	329.000000	168.333333	1254.666667	569.300000	295.933333	491.500000	216.633333	114.400000	853.966667	379.200000	198.633333
2015-05-31	392.387097	171.709677	96.709677	691.290323	299.000000	169.806452	718.225806	312.096774	178.903226	1249.000000	547.903226	303.548387	473.838710	206.451613	117.838710	827.709677	359.354839	205.387097

03 데이터 전처리와 시각화

<3개 국가의 월별 판매량 시각화 – lineplot 사용>

```
# Code Source : https://www.kaggle.com/subinium/tps-jan-happy-new-year
fig, ax = plt.subplots(1, 1, figsize=(12, 7))
train_monthly_country = train.set_index('date').groupby([pd.Grouper(freq='M'),'country'])[['num_sold']].mean()
sns.lineplot(x="date", y='num_sold', hue='country', data=train_monthly_country, ax=ax)

ax.set_ylabel('num_sold')
ax.set_title('Monthly Trend by Country', fontsize=15, fontweight='bold', loc='left')
ax.grid(alpha=0.5)
plt.show()
```

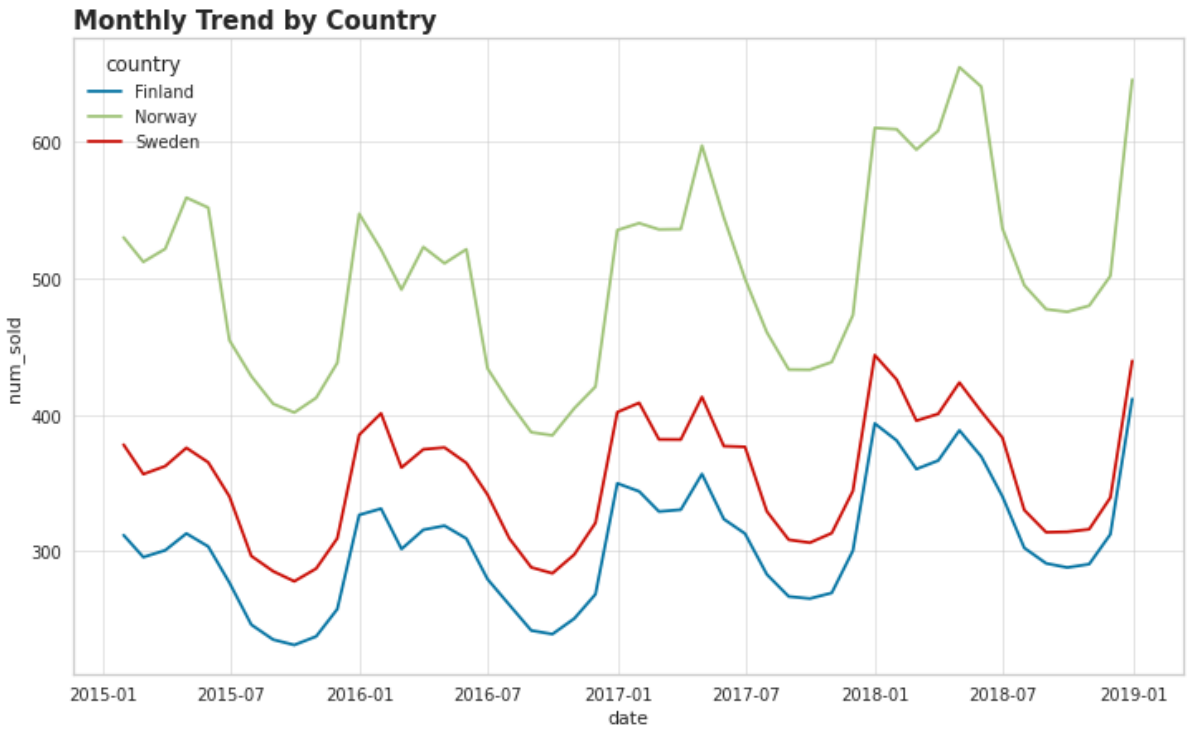

03 데이터 전처리와 시각화

<3개 국가의 요일별 판매량 시각화 – lineplot 사용>

```
# Code Source : https://www.kaggle.com/subinium/tps-jan-happy-new-year
fig, ax = plt.subplots(1, 1, figsize=(12, 7))
train_dayofweek = train.set_index('date').groupby([pd.Grouper(freq='M'), 'dayofweek'])[['num_sold']].mean()

sns.lineplot(x="date", y='num_sold', hue='dayofweek', data=train_dayofweek, ax=ax)
ax.set_title('Trend by day of the week', fontsize=15, fontweight='bold', loc='left')
ax.grid(alpha=0.5)
plt.show()
```

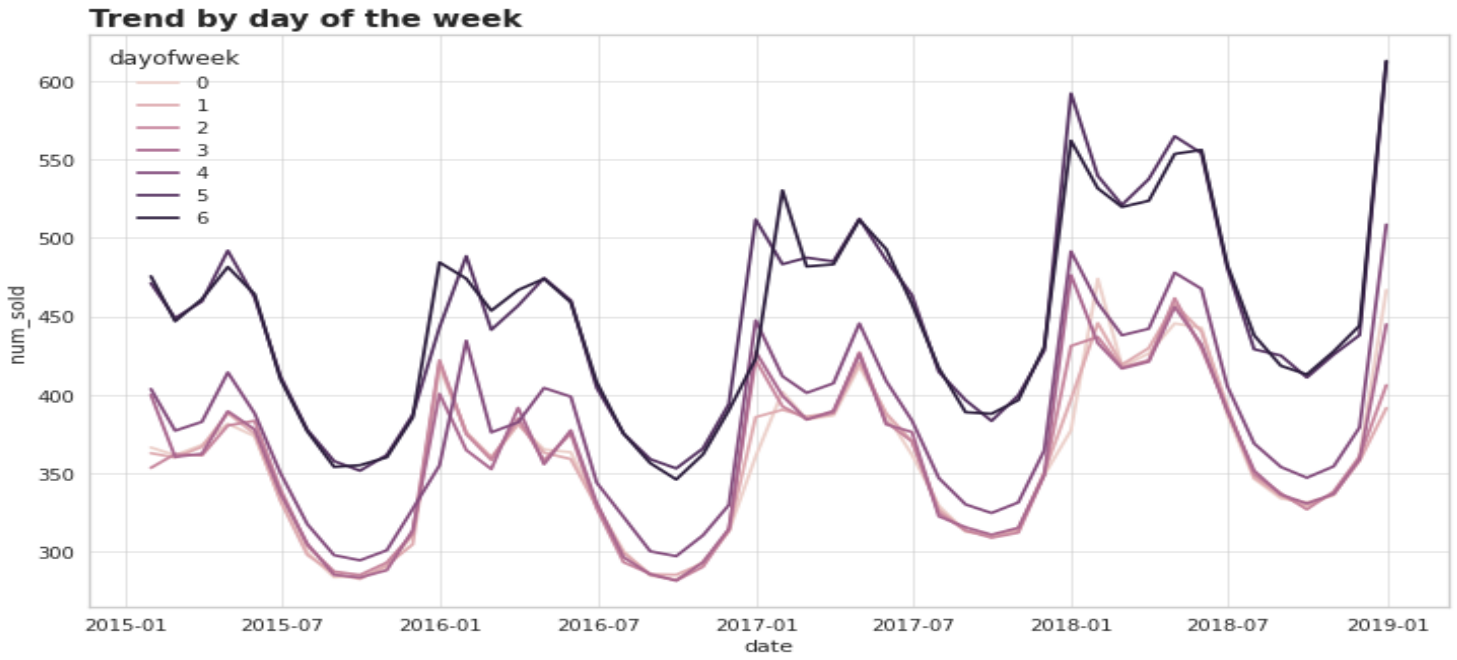

03 데이터 전처리와 시각화

<평일 VS 주말 판매여부 시각화 – lineplot 사용>

```
# Code Source : https://www.kaggle.com/subinium/tps-jan-happy-new-year
train['weekend'] = train['dayofweek'].apply(lambda x : x >= 5)
fig, ax = plt.subplots(1, 1, figsize=(12, 7))
train_weekend = train.set_index('date').groupby([pd.Grouper(freq='M'), 'weekend'])[['num_sold']].mean()
sns.lineplot(x="date", y="num_sold", hue='weekend', data=train_weekend, ax=ax)
ax.set_title('Weekend vs. Weekday Trend Comparison', fontsize=15, fontweight='bold', loc='left')
ax.grid(alpha=0.5)
plt.show()
```

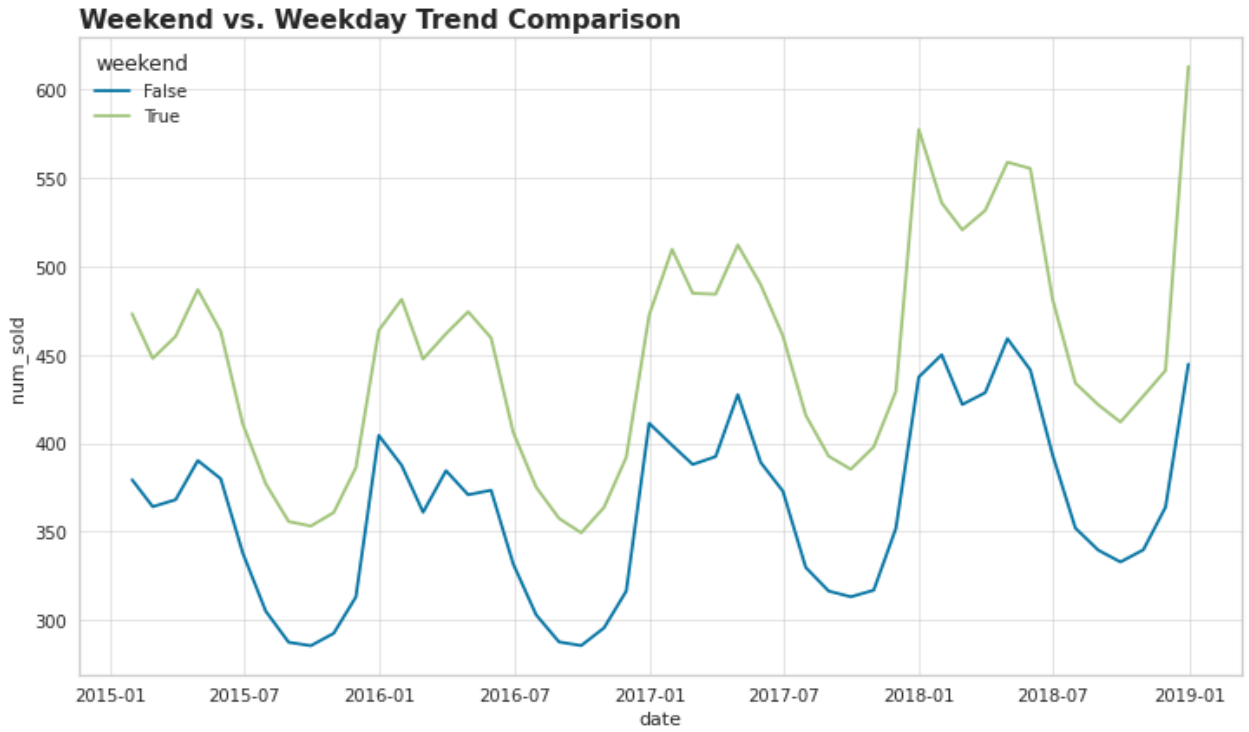

- ‘blend_model( )’(혼합 모델)

- 이 기법을 사용하면 여러 모델을 결합하여 앙상블 모델로 사용할 수 있다.

- 이 기법을 처음 최초로 사용되며 유명해진 건 2009년 ‘Netfrix’ 에서 열린 ‘Netfrix Prize’ 라는 대회에서 ‘Bellokor’s Pragmatic Chaos’ 라는 팀이 무려 2000시간의 작업 끝에 ‘107’개나 되는 알고리즘을 조합해 최종 우승한 일이다.

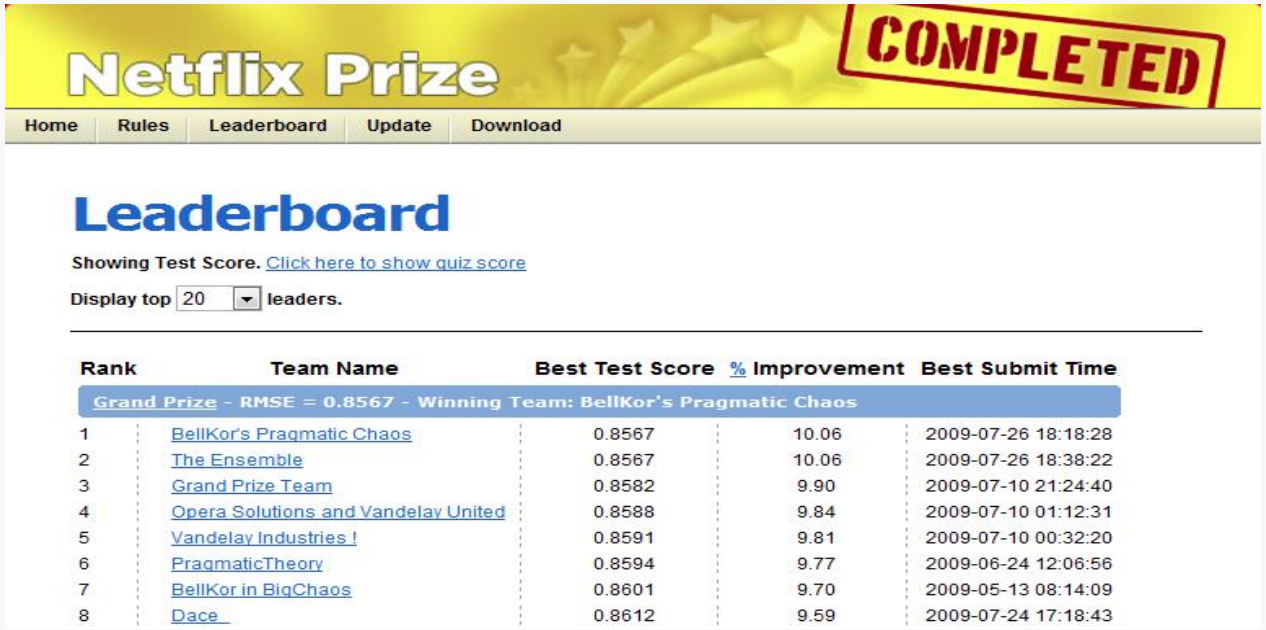

04 모델링

```
# Code sorce : https://www.kaggle.com/c/web-traffic-time-series-forecasting/discussion/36414
def SMAPE(y_true, y_pred):
    denominator = (y_true + np.abs(y_pred)) / 200.0
    diff = np.abs(y_true - y_pred) / denominator
    diff[denominator == 0] = 0.0
    return np.mean(diff)
```

- 모델링 부분에서 '핵심 코드' 이다 . 이유는 '데이터 셋'이 '시계열 ' 데이터인데 이 '시계열 ' 데이터를 연산을 하기 위해서는 꼭 필요한 코드.

```
# Code Sorce : https://www.kaggle.com/bernhardklinger/tps-jan-2022
add_metric('SMAPE', 'SMAPE', SMAPE, greater_is_better = False)
top =compare_models(sort = 'SMAPE',n_select = 3, include = ['catboost','lightgbm','xgboost'])
```

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	SMAPE	TT (Sec)
lightgbm	Light Gradient Boosting Machine	26.4653	2465.3168	46.3473	0.9654	0.0912	0.0669	6.6972	1.1100
xgboost	Extreme Gradient Boosting	27.0547	2557.9026	47.0485	0.9643	0.0942	0.0682	6.8439	0.4630
catboost	CatBoost Regressor	27.9218	3108.4708	50.1150	0.9582	0.0955	0.0688	6.8559	2.9060

- 상점의 판매 상품의 수량 이동 평균을 구하고 상위 3개의 모델을 성능 평가 지표를 비교해서 가장 적합한 모델 선택

04 모델링

```
# Code Sorce : https://www.kaggle.com/bernhardklinger/tps-jan-2022
blend = blend_models(top)
predict_model(blend)
```

- **Blend_models( )로 'top'안에 있는 'catboost', 'xgboost', 'lightGBM'을 혼합하고**
- **Predict_model을 사용해 예측 모델로 예측한 값을 출력한다.**

<실행 화면>

	MAE	MSE	RMSE	R2	RMSLE	MAPE	SMAPE
0	30.2732	3154.6394	56.1662	0.9605	0.1011	0.0695	7.0983
1	35.3577	2931.9545	54.1475	0.9576	0.1157	0.0996	9.3409
2	14.0553	416.3913	20.4057	0.9869	0.0560	0.0455	4.4633
3	27.6494	2496.3200	49.9632	0.9631	0.1008	0.0704	6.6572
4	34.7970	4276.4039	65.3942	0.9485	0.1155	0.0786	8.1803
5	19.6191	982.9176	31.3515	0.9776	0.0728	0.0590	5.7014
6	14.5871	444.8669	21.0919	0.9860	0.0583	0.0453	4.5510
7	34.6240	5853.6474	76.5091	0.9340	0.1155	0.0665	7.1345
8	34.5563	4197.2696	64.7863	0.9526	0.1139	0.0755	7.9464
9	15.4244	492.0150	22.1814	0.9872	0.0551	0.0443	4.4770
Mean	26.0943	2524.6426	46.1997	0.9654	0.0905	0.0654	6.5550
SD	8.7116	1810.8259	19.7542	0.0174	0.0254	0.0166	1.6254

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	SMAPE
0	Voting Regressor	42.5264	5711.7493	75.5761	0.9326	0.1196	0.0878	9.3386

	week	day	dayofyear	country_Finland	country_Norway	country_Sweden	store_KaggleRama	product_Kaggle Hat	product_Kaggle Mug	product_Kaggle Sticker	...	quarter_Q1	quarter_Q2	quarter_Q3	quarter_Q4	weekday_WD0	weekday_WD1
0	0.708333	0.2	0.707602	0.0	0.0	1.0	0.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
1	0.708333	0.2	0.707602	0.0	0.0	1.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
2	0.708333	0.2	0.707602	0.0	0.0	1.0	0.0	0.0	0.0	1.0	...	0.0	0.0	0.0	1.0	0.0	0.0
3	0.708333	0.2	0.707602	0.0	0.0	1.0	1.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
4	0.708333	0.2	0.707602	0.0	0.0	1.0	1.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
7885	-1.000000	1.0	1.134503	0.0	0.0	1.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7886	-1.000000	1.0	1.134503	0.0	0.0	1.0	0.0	0.0	0.0	1.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7887	-1.000000	1.0	1.134503	0.0	0.0	1.0	1.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7888	-1.000000	1.0	1.134503	0.0	0.0	1.0	1.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7889	-1.000000	1.0	1.134503	0.0	0.0	1.0	1.0	0.0	0.0	1.0	...	0.0	0.0	0.0	1.0	1.0	0.0

7890 rows × 27 columns

04 모델링

```
# Code Sorce : https://www.kaggle.com/bernhardklinger/tps-jan-2022
final_blend = finalize_model(blend)
predict_model(final_blend)
```

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	SMAPE
0	Voting Regressor	20.7123	1067.7249	32.6761	0.9874	0.0606	0.0476	4.8428

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	SMAPE
0	Voting Regressor	20.7123	1067.7249	32.6761	0.9874	0.0606	0.0476	4.8428

	week	day	dayofyear	country_Finland	country_Norway	country_Sweden	store_KaggleRama	product_Kaggle Hat	product_Kaggle Mug	product_Kaggle Sticker	...	quarter_Q1	quarter_Q2	quarter_Q3	quarter_Q4	weekday_WD0	weekday_WD1
0	0.708333	0.2	0.707602	0.0	0.0	1.0	0.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
1	0.708333	0.2	0.707602	0.0	0.0	1.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
2	0.708333	0.2	0.707602	0.0	0.0	1.0	0.0	0.0	0.0	1.0	...	0.0	0.0	0.0	1.0	0.0	0.0
3	0.708333	0.2	0.707602	0.0	0.0	1.0	1.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
4	0.708333	0.2	0.707602	0.0	0.0	1.0	1.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	0.0	0.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
7885	-1.000000	1.0	1.134503	0.0	0.0	1.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7886	-1.000000	1.0	1.134503	0.0	0.0	1.0	0.0	0.0	0.0	1.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7887	-1.000000	1.0	1.134503	0.0	0.0	1.0	1.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7888	-1.000000	1.0	1.134503	0.0	0.0	1.0	1.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	1.0	0.0
7889	-1.000000	1.0	1.134503	0.0	0.0	1.0	1.0	0.0	0.0	1.0	...	0.0	0.0	0.0	1.0	1.0	0.0

7890 rows × 27 columns

- ‘finalize_model( )’을 사용해 완성된 모델을 ‘final_blend( )’에 넣어준다.
- 마지막으로 ‘predict_model( )’로 최종 예측 값을 출력해 준다.

05 참고 자료

- https://blockdmask.tistory.com/411
- https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.pivot.html
- https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.set_index.html
- https://gibles-deepmind.tistory.com/41
- https://runebook.dev/ko/docs/pandas/reference/api/pandas.grouper
- https://keras.io/api/layers/base_layer/#metrics-property
- https://dacon.io/codeshare/2428
- https://pycaret.org/blend-models/
- https://pycaret.org/finalize-model/
- https://pycaret.org/predict-model/

Thank You