Classification with Tidymodels

1 TEAM
권도근
김재원
정승원
전우정

A Table of Contents

1 개요 및 대회 목적 개요 및 대회 목적 / 데이터 불러오기 / 탐색적 자료 분석 담당 :정승원

2 데이터 시각화 단변량 시각화 / 양적 변수 시각화 / 질적 변수 시각화 담당 :전우정,김재원

3 모델 학습 데이터분리 / 모델개발 / 모델 학습 비교 담당 :권도근

Part 1,

개요

새로운 ML 라이브러리인 Tidymodels 활용

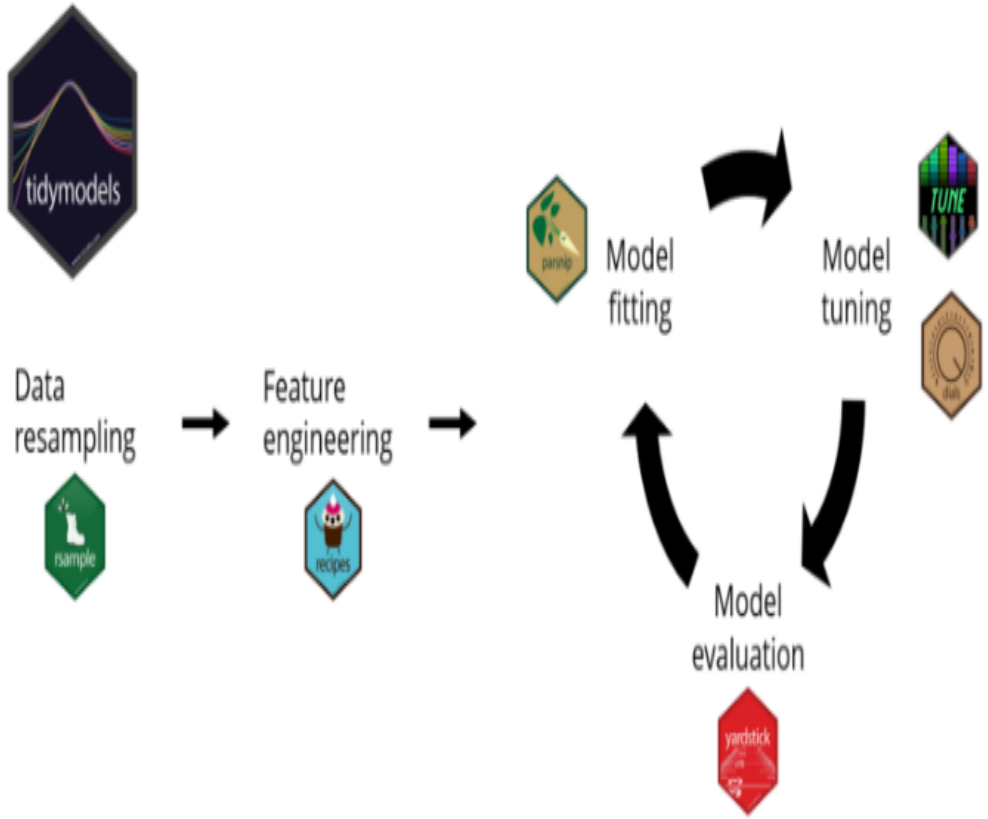

Part 1,

대회 목적

대출 승인 여부를 결정하는 모델

평가지표는 Accurarcy로 결정

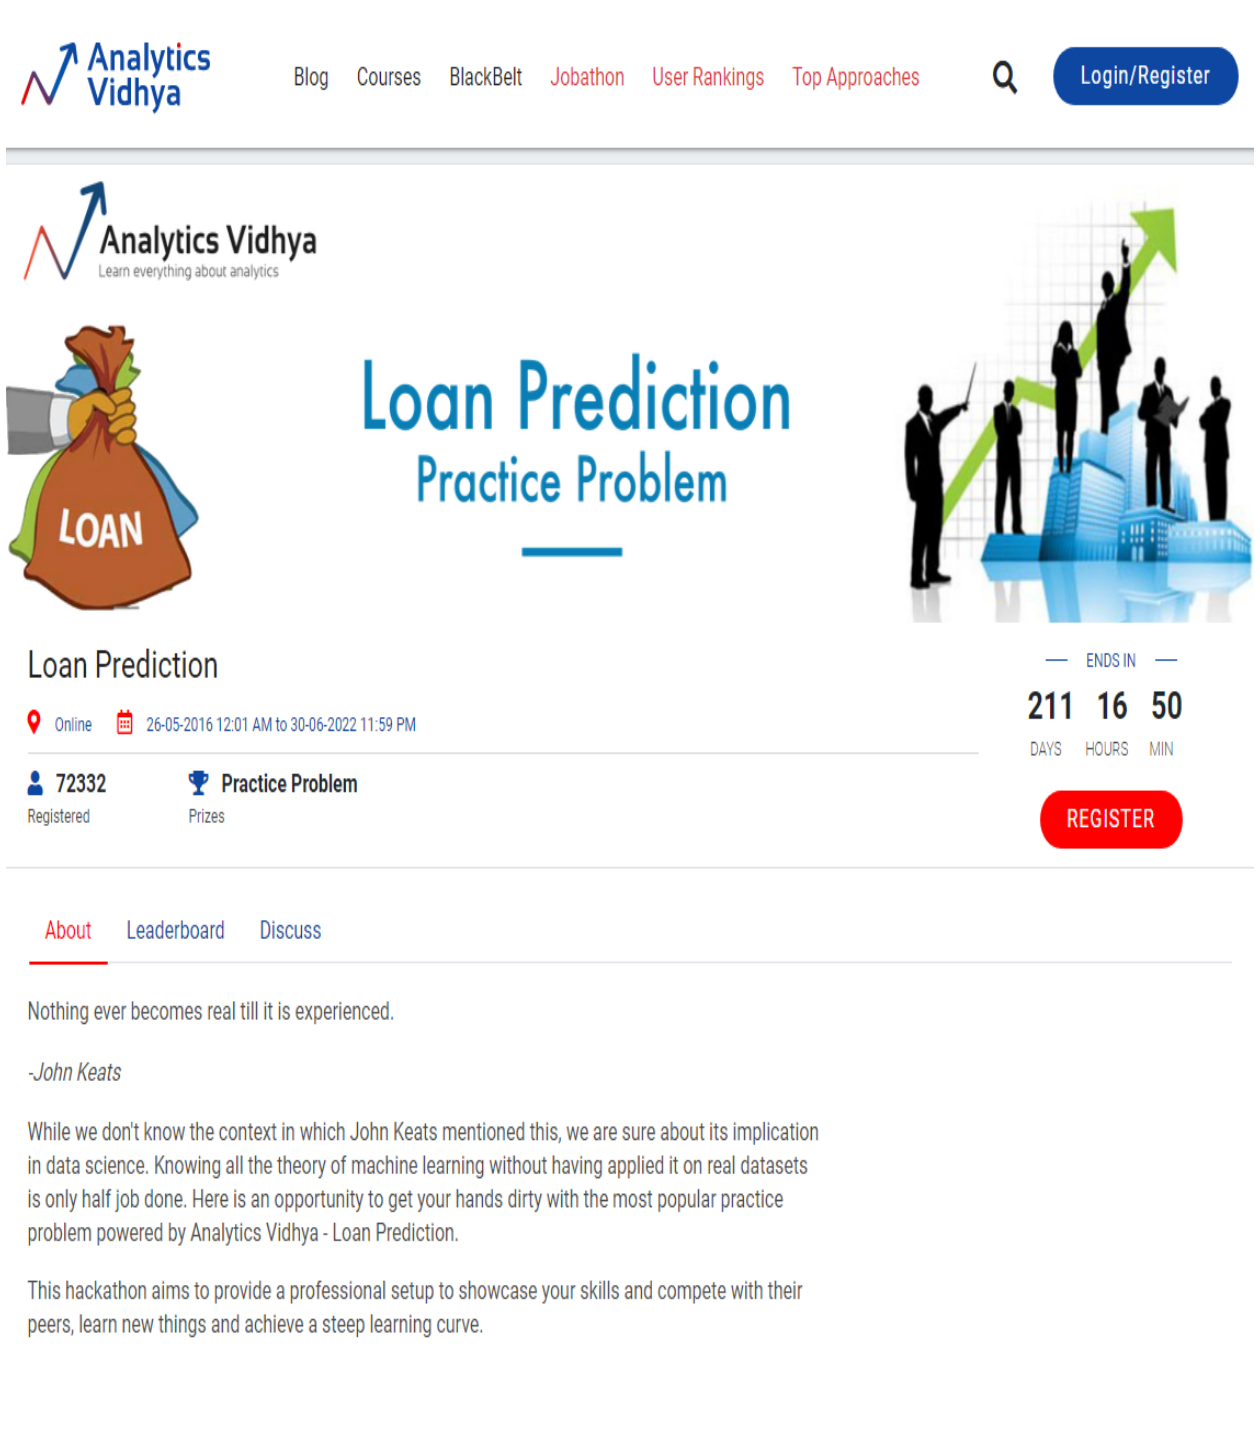

Part 1,

데이터 불러오기

Loan Prediction Practice Problem

Train file

Variable	Description
Loan_ID	Unique Loan ID
Gender	Male/ Female
Married	Applicant married (Y/N)
Dependents	Number of dependents
Education	Applicant Education (Graduate/ Under Graduate)
Self_Employed	Self employed (Y/N)
ApplicantIncome	Applicant income
CoapplicantIncome	Coapplicant income
LoanAmount	Loan amount in thousands
Loan_Amount_Term	Term of loan in months
Credit_History	credit history meets guidelines
Property_Area	Urban/ Semi Urban/ Rural
Loan_Status	(Target) Loan approved (Y/N)

Test file

Variable	Description
Loan_ID	Unique Loan ID
Gender	Male/ Female
Married	Applicant married (Y/N)
Dependents	Number of dependents
Education	Applicant Education (Graduate/ Under Graduate)
Self_Employed	Self employed (Y/N)
ApplicantIncome	Applicant income
CoapplicantIncome	Coapplicant income
LoanAmount	Loan amount in thousands
Loan_Amount_Term	Term of loan in months
Credit_History	credit history meets guidelines
Property_Area	Urban/ Semi Urban/ Rural

Submission 파일 의 데이터 명세서는 다음과 같다.

Variable	Description
Loan_ID	Unique Loan ID
Loan_Status	(Target) Loan approved (Y/N)

탐색적 자료 분석 (EDA)

Skim(train)

Data summary

Name	train
Number of rows	614
Number of columns	12
_____	
Column type frequency:	
character	8
numeric	4
_____	
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
Gender	13	0.98	4	6	0	2	0
Married	3	1.00	2	3	0	2	0
Dependents	15	0.98	1	2	0	4	0
Education	0	1.00	8	12	0	2	0
Self_Employed	32	0.95	2	3	0	2	0
Credit_History	50	0.92	1	1	0	2	0
Property_Area	0	1.00	5	9	0	3	0
Loan_Status	0	1.00	1	1	0	2	0

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
Applicant_Income	0	1.00	5403.46	6109.04	150	2877.5	3812.5	5795.00	81000	▇▁▁▁
CoApplicant_Income	0	1.00	1621.25	2926.25	0	0.0	1188.5	2297.25	41667	▇▁▁▁
Loan_Amount	22	0.96	146.41	85.59	9	100.0	128.0	168.00	700	▇▃▁▁
Loan_Amount_Term	14	0.98	342.00	65.12	12	360.0	360.0	360.00	480	▁▁▁▇

Part 2,

데이터 시각화

Part 2,

단변량 시각화

각 개별적인 컬럼에 대해 시각화를 자동으로 할 수 있는 코드를 작성

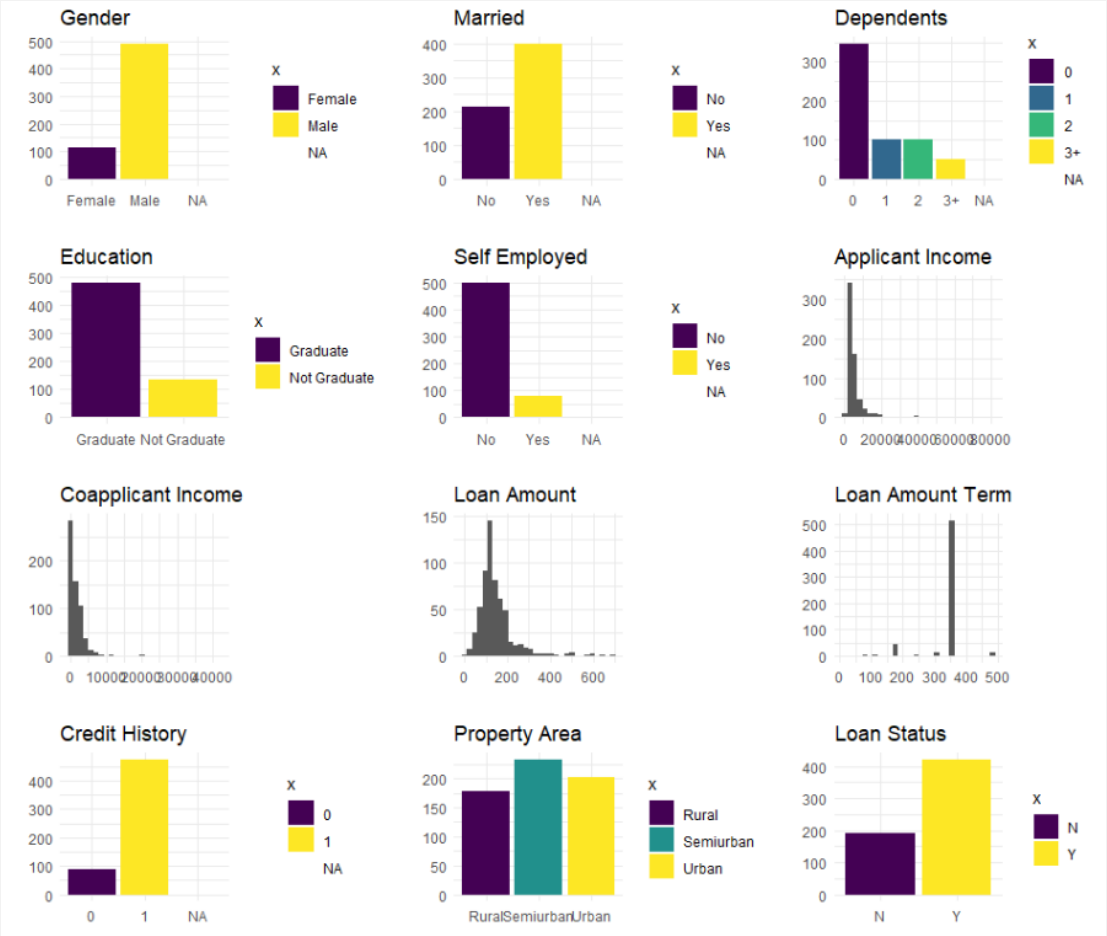

설명

- 대출 지원자의 성별은 남성이 여성보다 많음
- 대출 지원자의 결혼 유무는 기혼자가 더 많음
- 대출 지원자 중 상당수는 자녀가 없음
- 대출 지원자 중 상당수는 대학을 졸업했고, self-employed가 아님
- 대출 지원자의 수입은 right skewed
- Co-applicant의 수입도 right skewed
- 대출 지원자중 약 2/3는 대출 승인을 받음

Part 2,

양적변수 시각화

관계성을 확인하기에 용이

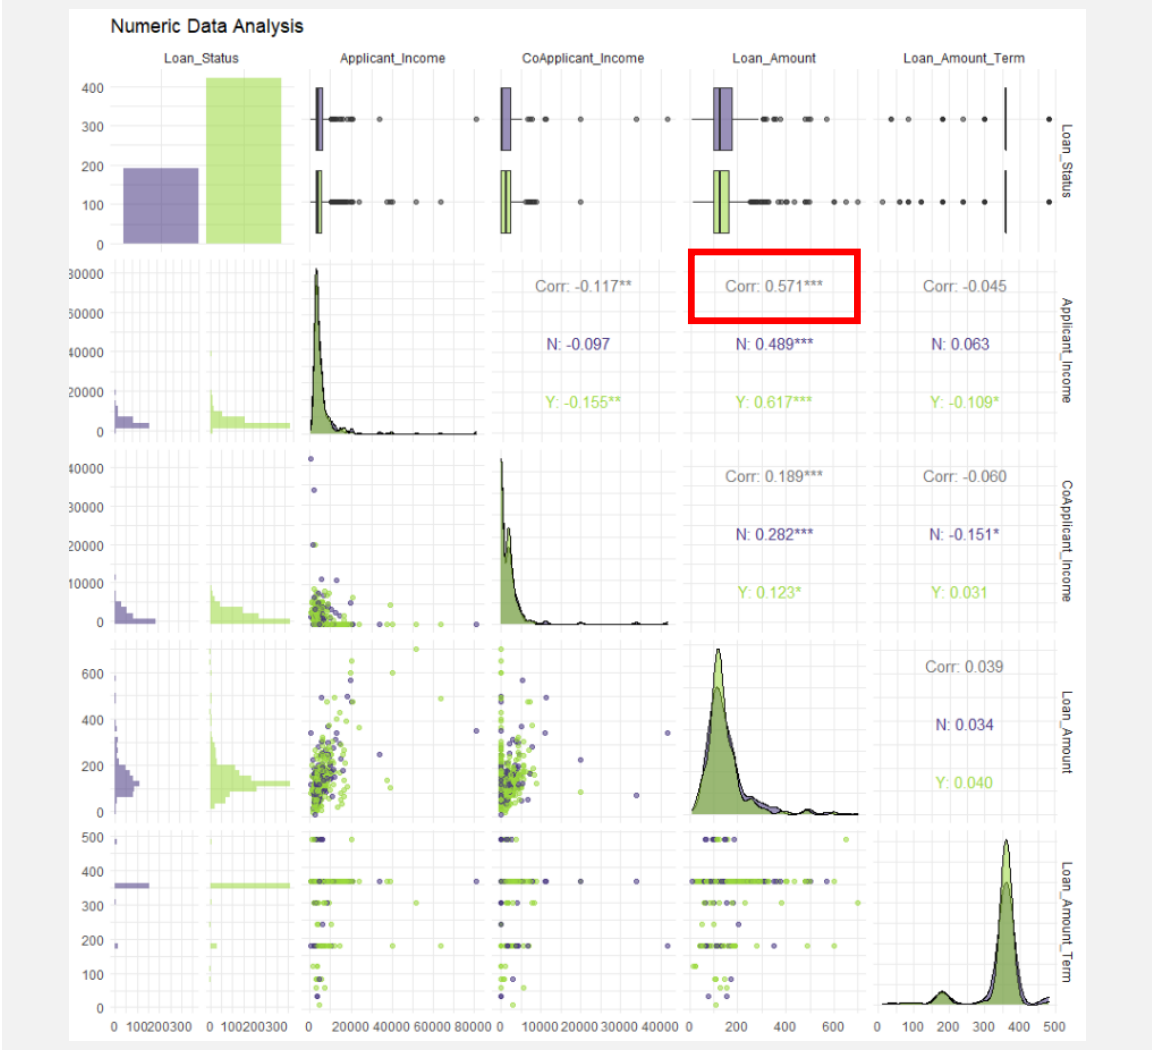

설명

Loan_Amount 와 Applicant_income

상관관계가 가장 큼

Part 2,

질적변수 시각화

평균과 신뢰구간

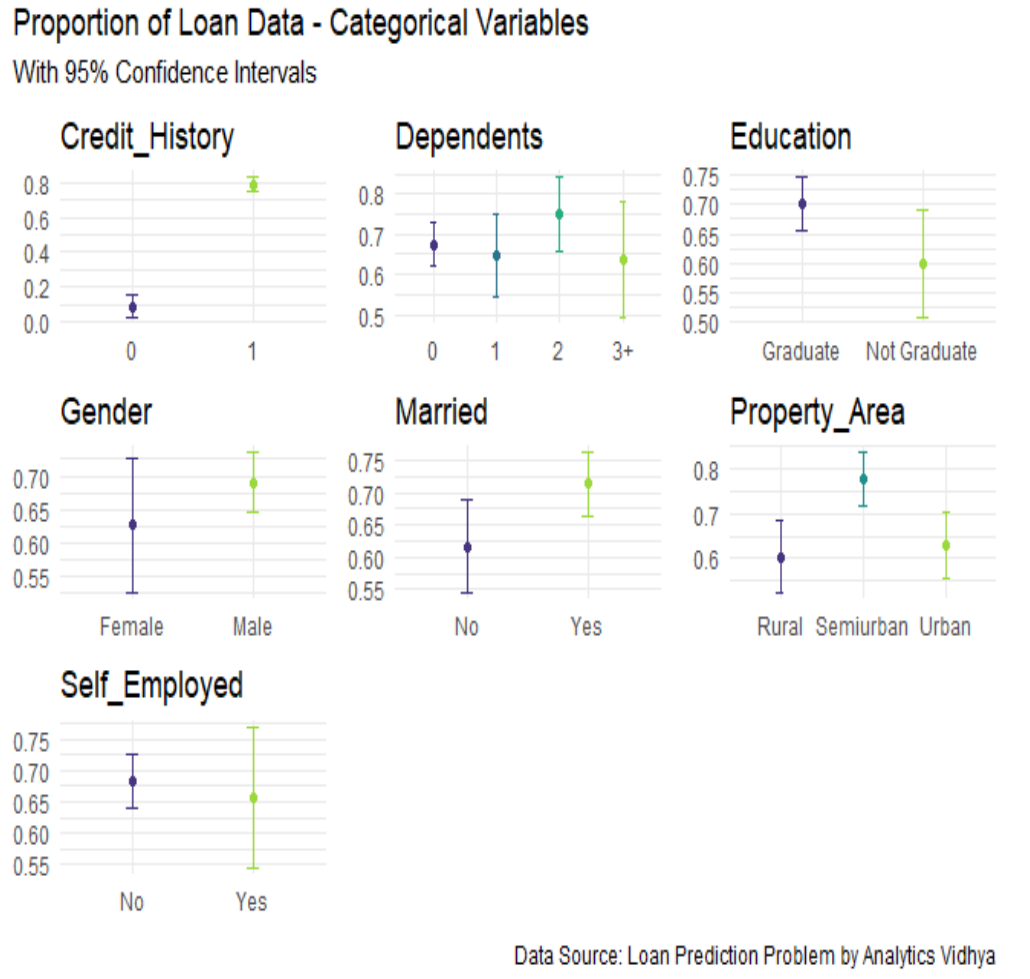

설명

- Married 지원자가 대출을 승인 받을 가능성이 높음
- 대졸자가 그렇지 않은 사람보다 대출을 승인 가능성 높음
- 자녀들 변수는 큰 영향 없음
- 여성 신청자수는 변동성이 크나 남성들은 작음
- Credit History의 유무에 따라 매우 큰 변동성

Part 3,

모델 학습

데이터 분리

층화추출기법(Stratified Sampling)을 통한 데이터 분리

층화추출(Stratified Sampling) 방식

조사대상을 몇 개의 그룹으로 구분

각 그룹에서 무작위로 **표본**을 **추출**하는 방법

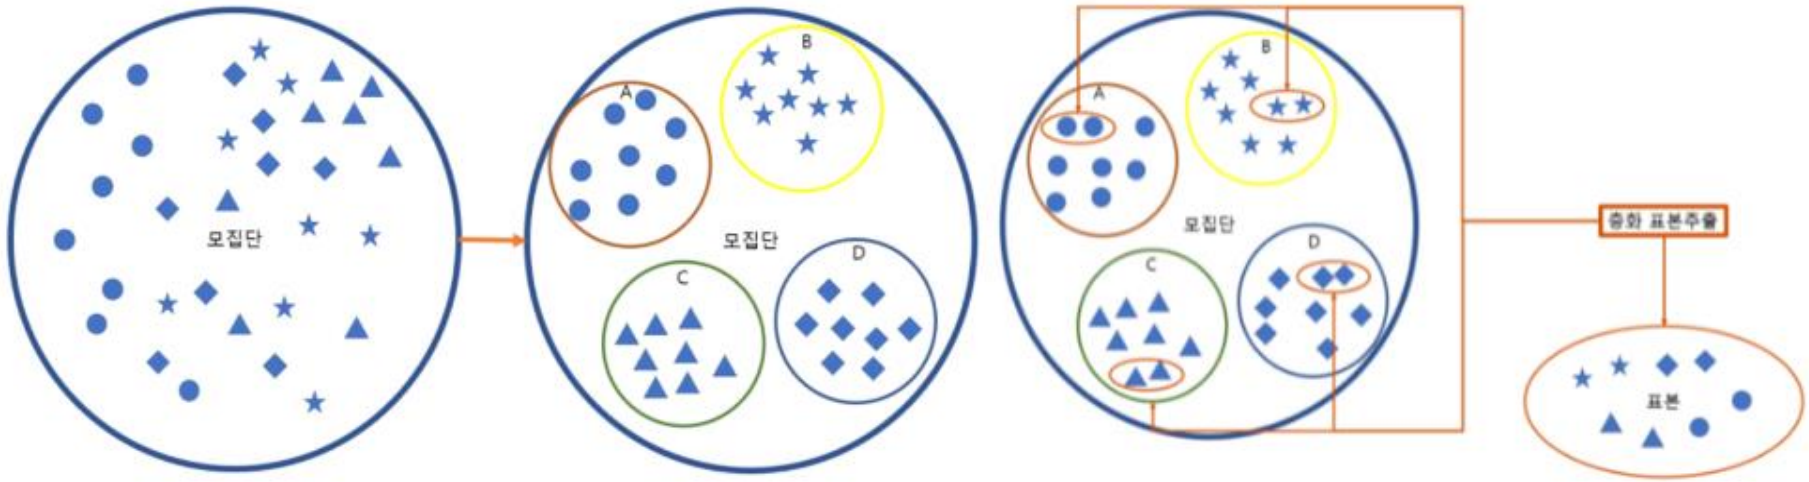

데이터 분리

층화추출기법(Stratified Sampling)을 통한 데이터 분리

층화추출(Stratified Sampling) 방식

장 점	단 점
모집단의 대표성 보장	모집단에서 층으로 분리할때 각층에 대한 정확한 사전 정보 필요
전체 모집단에서 층별로 구성 → 모집단 형성하는 모든 구성요소 포함	층화가 너무 복잡할 경우 표본 오차가 큼
층화표출을 통해 시간,비용 절약	층을 명확히 구분하지 않을 경우 불필요한 층화 추출 가능성

Part 3,

모델 개발

Logistic, decision tree, random forest, xgboost 총 4개의 모델을 개발

STEP 1

모델 개발

분류 모형 개발
logistic
decision tree
random forest
Xgboost
총 4개의 모델

>>

STEP 2

Feature Engineering

Tidymodels에서는 Feauture Engineering을 사용하기위해 recipe 함수 사용

결측치 처리를 위해 bagged tree models, impute_mean, impute_node 등을 사용

>>

STEP 3

Correlation Graph

상관관계그래프 작성

Train & validation 데이터 합치기

>>

STEP 4

시각화 작성

모델 개발

Correlation Graph

```
## # A tibble: 15 x 16
##    term                Property_Area_Urb~ Loan_Amount Applicant_Income Gender_Male
##    <chr>                            <dbl>       <dbl>            <dbl>       <dbl>
##  1 Property_Area_Ur~           NA           -0.0419         -0.000598     0.0374
##  2 Loan_Amount                 -0.0419      NA               0.579        0.0967
##  3 Applicant_Income            -0.000598     0.579          NA            0.0559
##  4 Gender_Male                  0.0374       0.0967          0.0559      NA
##  5 Dependents_X3.              -0.0475       0.144           0.157        0.0820
##  6 Married_Yes                  0.00294      0.147           0.0491       0.376
##  7 CoApplicant_Inco~            0.0228       0.182          -0.117        0.0850
##  8 Dependents_X1                0.0812       0.0559          0.0392      -0.00964
##  9 Self_Employed_Yes           -0.0234       0.123           0.123       -0.0212
## 10 Education_Not.Gr~           -0.0343      -0.175          -0.141        0.0474
## 11 Dependents_X2                0.0226       0.0181         -0.0315       0.138
## 12 Loan_Amount_Term            -0.0978       0.0397         -0.0458      -0.0742
## 13 Credit_History              -0.0335      -0.0154         -0.00502      0.0177
## 14 Loan_Status                 -0.0436      -0.0385         -0.00471      0.0151
## 15 Property_Area_Se~           -0.548       -0.00667        -0.0142      -0.114
## # ... with 11 more variables: Dependents_X3. <dbl>, Married_Yes <dbl>,
## #   CoApplicant_Income <dbl>, Dependents_X1 <dbl>, Self_Employed_Yes <dbl>,
## #   Education_Not.Graduate <dbl>, Dependents_X2 <dbl>, Loan_Amount_Term <dbl>,
## #   Credit_History <dbl>, Loan_Status <dbl>, Property_Area_Semiurban <dbl>
```

시각화

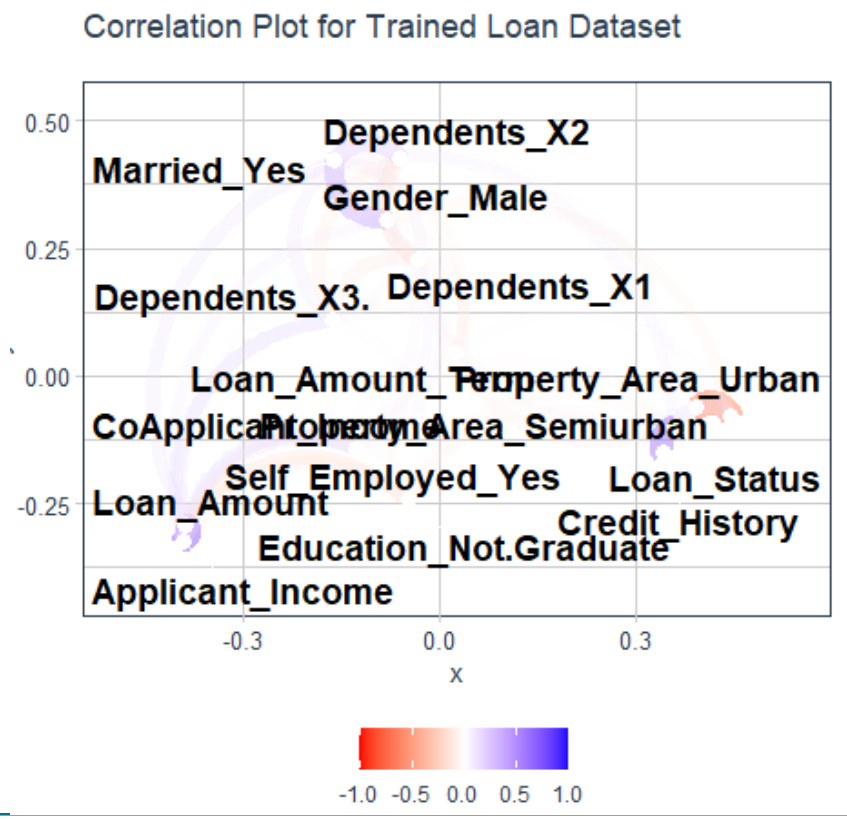

모델 개발

Correlation Graph

```
## # A tibble: 15 x 16
## # ... with 11 more variables: Dependents_X3. <dbl>, Married_Yes <dbl>,
## #   CoApplicant_Income <dbl>, Dependents_X1 <dbl>, Self_Employed_Yes <dbl>,
## #   Education_Not.Graduate <dbl>, Dependents_X2 <dbl>, Loan_Amount_Term <dbl>,
## #   Credit_History <dbl>, Loan_Status <dbl>, Property_Area_Semiurban <dbl>
```

Loan_Status

Credit_History

가장 연관성이 큰 데이터

시각화

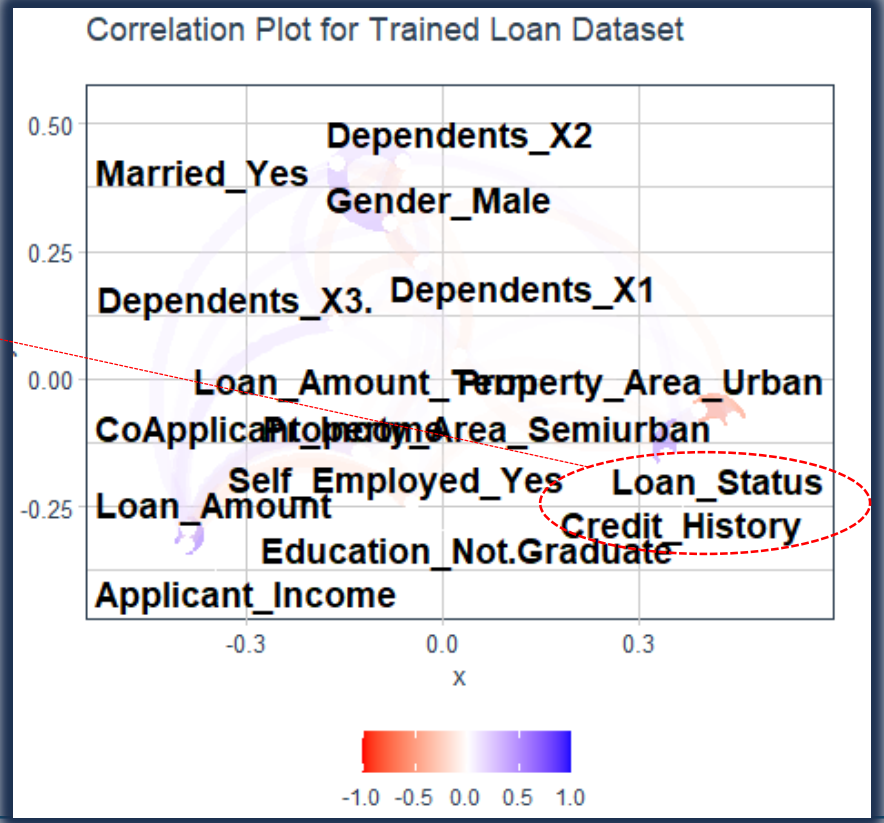

Part 3,

모델 학습

Decision-Tree , Logistic-Regression , Random-Forest , XGBoost

```
## i 1 of 8 tuning:     Recipe1_Random_Forest
## i Creating pre-processing data to finalize unknown parameter: mtry
## v 1 of 8 tuning:     Recipe1_Random_Forest (1m 25.6s)
## i 2 of 8 tuning:     Recipe1_Decision_Tree
## v 2 of 8 tuning:     Recipe1_Decision_Tree (43.9s)
## i 3 of 8 tuning:     Recipe1_Logistic_Regression
## v 3 of 8 tuning:     Recipe1_Logistic_Regression (42.1s)
## i 4 of 8 tuning:     Recipe1_XGBoost
## i Creating pre-processing data to finalize unknown parameter: mtry
## v 4 of 8 tuning:     Recipe1_XGBoost (1m 49.4s)
## i 5 of 8 tuning:     Recipe2_Random_Forest
## i Creating pre-processing data to finalize unknown parameter: mtry
## v 5 of 8 tuning:     Recipe2_Random_Forest (1m 3.7s)
## i 6 of 8 tuning:     Recipe2_Decision_Tree
## v 6 of 8 tuning:     Recipe2_Decision_Tree (29.2s)
```

```
## i 7 of 8 tuning:     Recipe2_Logistic_Regression
## v 7 of 8 tuning:     Recipe2_Logistic_Regression (32.7s)
## i 8 of 8 tuning:     Recipe2_XGBoost
## i Creating pre-processing data to finalize unknown parameter: mtry
## v 8 of 8 tuning:     Recipe2_XGBoost (1m 43.9s)
```

모델 학습

- Decision-tree
- Logistic-Regression
- Random-Forest
- XGBoost

Part 3,

모델 학습 비교

Decision-Tree , Logistic-Regression , Random-Forest , XGBoost

시각화를 통한 모델 비교

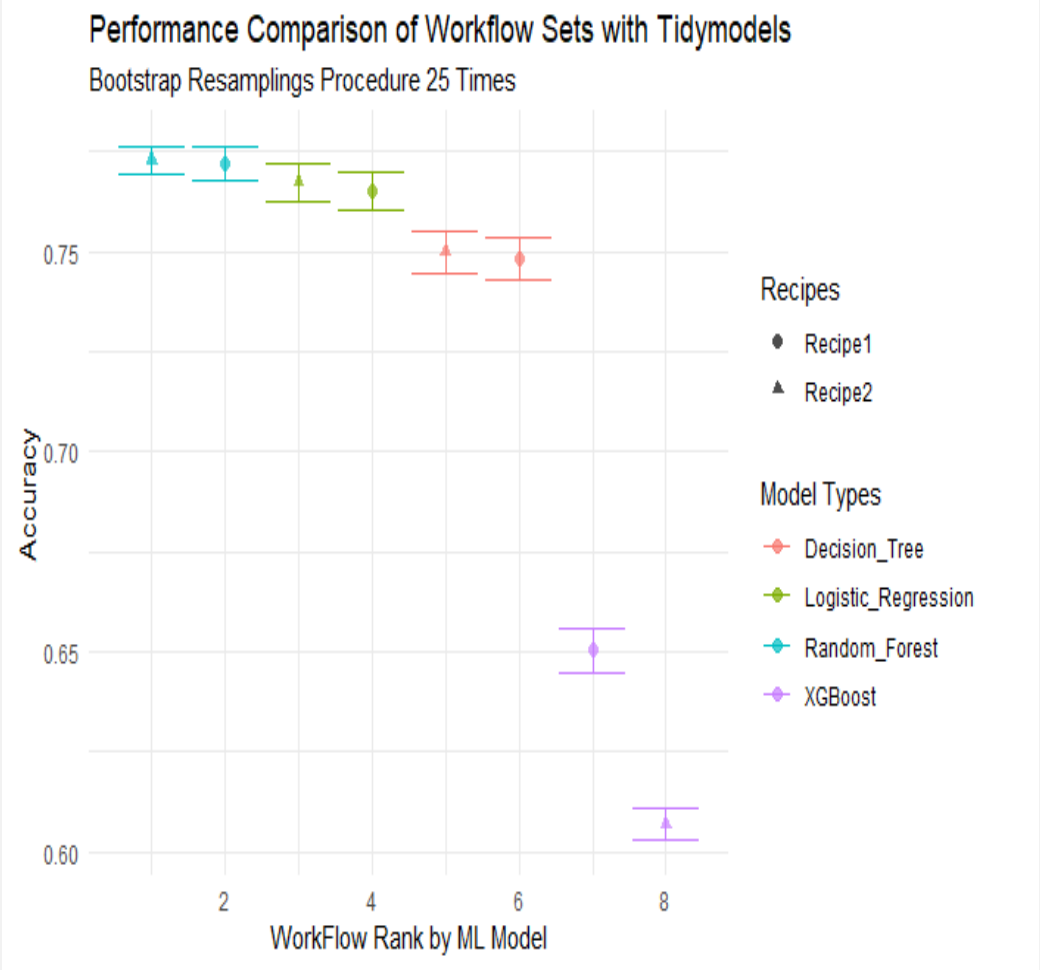

모델 정확도 순위

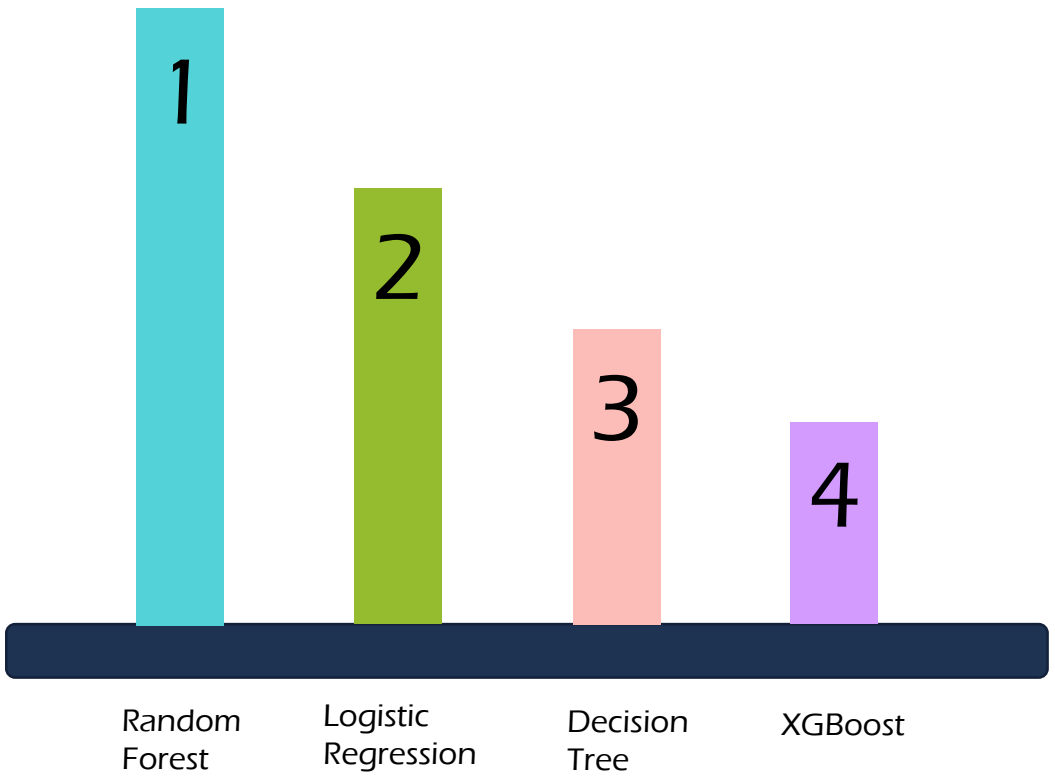

Random Forest (Recipe2)가 가장 적합한 모델

감사합니다.

ⓒSaebyeol Yu. Saebyeol's PowerPoint